

目录

线性方程组 2

1.概念2

2.矩阵2

2.1 矩阵引入 2

2.2 线性方程组的求解3

2.3 主元 3

3.向量方程4

3.1 向量4

3.2 线性组合 5

4.矩阵方程 $Ax = b$ 6

4.1 矩阵相乘在神经网络的应用 6

4.2 齐次线性方程与线性相/无关8

线性方程组

1.概念

包含未知数 x_1, x_2, \dots, x_n 的一个**线性方程**是形如

$$a_1x_1 + a_2x_2 + \dots + a_nx_n = b$$

的方程，其中 b 与系数 a_1, a_2, \dots, a_n 是实数或复数，通常是已知数。

而**线性方程组**是由一个或多个包含相同变量 x_1, x_2, \dots, x_n 的线性方程组成的。例如

$$\begin{cases} 2x_1 - x_2 + 1.5x_3 = 8 \\ x_1 - 4x_3 = -7 \end{cases}$$

线性方程组的一组解是一组数 (s_1, \dots, s_n) ，用这组数分别代替 x_1, x_2, \dots, x_n 时所有方程的两边相等。例如 $(5, 6.5, 3)$ 代入方程组变成等式 $8 = 8$ 和 $7 = -7$ 。

方程组所有可能的解的集合称为线性方程组的**解集**。若是两个线性方程组有相同的解集，则它们等价。

求包含两个未知数的两个方程组成的方程组的解，等价于求两条直线的交点，例如

$$\begin{cases} x_1 - 2x_2 = -1 \\ -x_1 + 3x_2 = 2 \end{cases}$$

这两个方程的图形都是直线，两条直线可能交于一点、不相交(平行)、重合，分别对应于一个解、无解、无穷多解的情况。

2.矩阵

2.1 矩阵引入

一个线性方程组包含的主要信息可以用**矩阵**表示，给出方程组

$$\begin{cases} x_1 - 2x_2 + x_3 = 0 \\ 2x_2 - 8x_3 = 8 \\ -4x_1 + 5x_2 + 9x_3 = -9 \end{cases}$$

把每一个变量的系数写在对齐的一列中，矩阵

$$\begin{bmatrix} 1 & -2 & 1 \\ 0 & 2 & -8 \\ -4 & 5 & 9 \end{bmatrix}$$

称之为该方程组的**系数矩阵**，而

$$\begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 2 & -8 & 8 \\ -4 & 5 & 9 & -9 \end{bmatrix}$$

称之为增广矩阵。

2.2 线性方程组的求解

基本的思路是把方程组用一个更容易解的等价方程组代替。

粗略地说，我们用第一个方程组中第一个方程中含 x_1 的项消去其他方程中的含 x_1 的项，然后用第二个方程中含 x_2 的项消去其他方程中含 x_2 的项，以此类推，最后得到一个很简单的等价方程组(阶梯状的方程组)。

例如

$$\begin{cases} x_1 - 2x_2 + x_3 = 0 \\ 2x_2 - 8x_3 = 8 \\ -4x_1 + 5x_2 + 9x_3 = -9 \end{cases} \quad \begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 2 & -8 & 8 \\ -4 & 5 & 9 & -9 \end{bmatrix}$$

可以将第一个方程*4 加上第 3 个方程，从而得到新的方程 3.如下所示

$$\begin{array}{l} 4 \cdot [\text{方程 1}]: 4x_1 - 8x_2 + 4x_3 = 0 \\ + [\text{方程 3}]: -4x_1 + 5x_2 + 9x_3 = -9 \\ \hline [\text{新方程 3}]: -3x_2 + 13x_3 = -9 \end{array}$$

就可以得到一个新的方程组和矩阵。以此类推最终得到阶梯状的方程组为

$$\begin{cases} x_1 - 2x_2 + x_3 = 0 \\ x_2 - 4x_3 = 4 \\ x_3 = 3 \end{cases} \quad \begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 1 & -4 & 4 \\ 0 & 0 & 1 & 3 \end{bmatrix}$$

就这样，我们可以很容易地知道原方程组的解为(29,16,3)。

下面我们引入行初等变换：

1. (倍加变换) 把某一行换成它本身与另一行的倍数的和。
2. (对数变换) 把两行对换。
3. (倍乘变换) 把某一行的所有元素乘以同一个非零数。

若其中一个矩阵经过若干行初等变换变换为另一个矩阵，我们称这两个矩阵为行等价的。

2.3 主元

对于一个阶梯型矩阵，我们定义**主元元素**与**主元列**。下面是几个概念：

先导元素：(非零行中)该行最左边的非零元素。

主元位置：阶梯型矩阵中先导元素的位置

主元列：含有先导元素的列

我们举个例子，如下所示

$$\begin{bmatrix} 1 & 4 & 5 & -9 & -7 \\ 0 & 2 & 4 & -6 & -6 \\ 0 & 0 & 0 & -5 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

可以知道，主元列是第 1、2、4 列，主元为 1、2、-5.

通过先前的知识可以知道，矩阵可以对应于一个线性方程组，例如：

$$\begin{bmatrix} 1 & 0 & -5 & 1 \\ 0 & 1 & 1 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} \rightarrow \begin{cases} x_1 - 5x_3 = 1 \\ x_2 + x_3 = 4 \\ 0 = 0 \end{cases}$$

对应于主元列的变量 x_1 和 x_2 称为**基本变量**，其他变量(x_3)称为**自由变量**。

3.向量方程

3.1 向量

仅含一列的矩阵称为**列向量**，或简称**向量**。

若 n 是正整数， \mathbb{R}^n 表示所有 n 个实数数列(或有序 n 元组)的集合，通常写成 $n \times 1$ 列矩阵的形式，如

$$\vec{u} = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

所有元素都是零的向量称为零向量，用 $\vec{0}$ 表示。

下面举个例子：

$$\vec{u} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}, \vec{w} = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$$


这里 w_1 和 w_2 是任意实数。所有的两个元素的向量的集记为 \mathbb{R}^2 ， \mathbb{R} 表示向量中的元素是实数，而指数 2 表示每个向量包含两个元素。

向量之间是可以做加减的，就是对应元素做加减得到新的向量；也支持和实数做标量乘法，就是实数与每个元素做乘法得到新的向量。

有时为了方便，我们会将列向量写成括号的形式，例如

$$\begin{bmatrix} 3 \\ -1 \end{bmatrix} \rightarrow (3, -1)$$

可以理解为是一个集合点对， \mathbb{R}^2 看作是平面上所有点的集合，而向量的几何表示是一条由原点(0,0)指向点(3,-1)的有向线段，如图。



其他维度的也同理。


3.2 线性组合

给定 \mathbb{R}^n 中向量 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$ 和标量 c_1, c_2, \dots, c_p , 向量

$$\vec{y} = c_1 \vec{v}_1 + \dots + c_p \vec{v}_p$$

称为向量 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$ 以 c_1, c_2, \dots, c_p 为权的**线性组合**。

线性组合可以在几何上去理解, 线性组合后的向量与其他向量一样, 均是空间中的一个点。它的形成方式如下所示



也就是例如

$$\vec{u} = 3\vec{v}_1 - 2\vec{v}_2$$

可以当成是从原点开始沿着 \vec{v}_1 的方向走了三个单位, 再沿着 \vec{v}_2 方向走了-2个单位。

线性代数的一个主要思想是研究可以表示为某一固定向量集合 $\{\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p\}$ 的线性组合的所有向量。若 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$ 是 \mathbb{R}^n 中的向量, 则 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$ 的所有线性组合所称的集合用记号 $\text{Span}\{\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p\}$ 表示称为由 $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p$ 所生成(或张成)的 \mathbb{R}^n 的子集, 也就是说, $\text{Span}\{\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p\}$ 是所有形如

$$c_1 \vec{v}_1 + \dots + c_p \vec{v}_p$$

的向量的集合, 其中 c_1, \dots, c_p 为标量。

要判断向量 \vec{b} 是否属于 $\text{Span}\{\vec{v}_1, \vec{v}_2, \dots, \vec{v}_p\}$, 就是判断向量方程

$$x_1 \vec{v}_1 + \dots + x_p \vec{v}_p = \vec{b}$$

是否有解, 或等价地, 判断增广矩阵 $[\vec{v}_1 \dots \vec{v}_p \mid \vec{b}]$ 的线性方程组是否有解。注意, 一定包含零向量。

下面是 $\text{Span}\{\vec{u}\}$ 与 $\text{Span}\{\vec{u}, \vec{v}\}$ 的几何解释。

设 \vec{u} 是 \mathbb{R}^3 中的向量, 那么 $\text{Span}\{\vec{u}\}$ 就是 \vec{u} 的所有数量倍数的集合, 也就是通过 \vec{u} 和 $\vec{0}$ 的直线上所有点的集合。

若 \vec{u} 和 \vec{v} 是 \mathbb{R}^3 的非零向量, \vec{v} 不是 \vec{u} 的倍数, 则 $\text{Span}\{\vec{u}, \vec{v}\}$ 是 \mathbb{R}^3 中通过 \vec{u} 、 \vec{v} 和 $\vec{0}$ 的平面, 可

以结合我们之前的线性组合的几何理解上去理解。




图 1-16 $\text{Span}\{v\}$ 是通过原点的直线




图 1-17 $\text{Span}\{u, v\}$ 是通过原点的平面

4. 矩阵方程 $A\vec{x} = \vec{b}$

线性代数的一个基本思想是把向量的线性组合看作矩阵与向量的积。

若 A 是 $n \times m$ 矩阵，它的各列为 a_1, \dots, a_n 。若 \vec{x} 是 \mathbb{R}^n 中向量，则 A 与 \vec{x} 的积，记为 $A\vec{x}$ ，就是 A 的各列以 \vec{x} 中对应元素为权的线性组合，即

$$A\vec{x} = [\vec{a}_1 \ \vec{a}_2 \ \dots \ \vec{a}_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \vec{a}_1 + x_2 \vec{a}_2 + \dots + x_n \vec{a}_n$$

注意维度要求， A 的列数必须要等于 \vec{x} 中的元素个数。例如

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & -5 & 3 \end{bmatrix} \begin{bmatrix} 4 \\ 3 \\ 7 \end{bmatrix} = 4 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 3 \begin{bmatrix} 2 \\ -5 \end{bmatrix} + 7 \begin{bmatrix} -1 \\ 3 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \end{bmatrix}$$

通过这个例子，相信能更好的理解矩阵相乘(即为什么要第一个矩阵的列数要等于第二个矩阵的行数)，还可以结合神经网络的前向传播来理解。

定理 设 A 是 $n \times m$ 矩阵，则下列命题是逻辑上等价的，也就是说，对某个 A ，它们都成立或者都不成立。

- 对 \mathbb{R}^m 中的每个 \vec{b} ，方程 $A\vec{x} = \vec{b}$ 有解
- \mathbb{R}^m 中的每个 \vec{b} 都是 A 的列的一个线性组合
- A 的各列生成 \mathbb{R}^m
- A 在每一列都有一个主元位置

其实要理解不难，a 和 d 是等价的，每一列均有一个主元，即阶梯型的矩阵每一列均不会出现 $0=b$ 的情况，可以从最后一行开始逐步往上求解，所以 a 也是成立的。


对于 b，因为 A 是一个可以到达最后一行的阶梯型的矩阵，所以自然是可以表示出任何 m 行向量。

4.1 矩阵相乘在神经网络的应用


这一小节介绍一下矩阵计算在神经网络中的应用，有助于加深理解。

神经网络中最基本的成分就是神经元模型。和生物的神经元类似，神经元和其他神经元相连，当它“兴奋”时就会向其他神经元发送物质，当其他神经元接收到了物质超过了一定的阈值，就会接着往其他神经元发送物质。

神经网络中的神经元也是如此，可以将其抽象为如下图所示。 $x_1 + x_2 + x_3$ 为输入，如果超过了阈值就触发激活函数，并产生输出传给下一个神经元。这一过程，我们称之为前向传播。



下面就是介绍如何利用矩阵相乘来快速计算前向传播。我们给出一个神经网络其中两层的传播过程，如下所示



其中，我们描述下前向传播的过程：

- 前一层包含 n 个结点，后一层包含 m 个点，两层之间的结点都是全连接的。
- 每一条连接边都带有一个权重 w ，每一个连接边的输入都会乘以权重。
- 后一层的每个结点都会接收来自前一层的 n 个输入，接收的输入累加，再加上一个结点所带的偏置 b 。
- 加上偏置后得到 y ， y 会再经过一个激活函数成为下一层的输入 $f(y)$ ，特别说明，为了简化接下来的计算，我们将不考虑激活函数。

根据我们的描述，可以得到如下方程组：

$$\begin{cases} w_{11}x_1 + w_{12}x_2 + \cdots + w_{1n}x_n + b_1 = y_1 \\ w_{21}x_1 + w_{22}x_2 + \cdots + w_{2n}x_n + b_2 = y_2 \\ \vdots \\ w_{m1}x_1 + w_{m2}x_2 + \cdots + w_{mn}x_n + b_m = y_m \end{cases}$$

是不是很熟悉，这就是一个线性方程组，我们可以将其写为矩阵相乘的形式，如下所示

$$\begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ w_{m1} & w_{m2} & \cdots & w_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

由此可看出，一个神经网络的前向传播过程是可以用矩阵运算替代的。

众所周知，目前用 GPU 训练神经网络比 CPU 要快好几个数量级，其原因就在于 GPU 是成千上万个小处理器核心构成的，CPU 最多有几十个大处理器核心，因此 GPU 处理矩阵运算具有巨大优势（GPU 负责图形处理，例如游戏效果）。虽然 CPU 每个核心的综合能力强很多，但面对神经网络大量的并行加减乘除运算，就不如 GPU 并行处理速度快了。

4.2 齐次线性方程与线性相/无关

若它可以写成 $A\vec{x} = \vec{0}$ 的形式，则称该线性方程组为**齐次线性方程组**。这样的方程组至少

有一个解，即 $\vec{x} = \vec{0}$ ，这个解称为它的**平凡解**。我们往往关注的是它的非平凡解。

我们将矩阵方程转换为向量方程，例如考虑方程

$$x_1 \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} + x_2 \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix} + x_3 \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

此方程当然有平凡解，即 $x_1 = x_2 = x_3 = 0$ ，不过我们更关心的是平凡解是否是唯一解。

我们定义，若向量方程仅有平凡解， \mathbb{R}^n 中的一组向量 $\{v_1, \dots, v_p\}$ 称为**线性无关**的，如下所示

$$x_1 \vec{v}_1 + \cdots + x_p \vec{v}_p = \vec{0}$$

若存在不全为零的权 c_1, \dots, c_p ，使下式成立，则称向量组(集) $\{v_1, \dots, v_p\}$ 称为**线性相关**的

$$c_1 \vec{v}_1 + \cdots + c_p \vec{v}_p = \vec{0}$$